



ML Final ๑๑๑๑๑!!

1. KNN

2. Decision Tree ✓ แล้ว ฝึก

3. Neural Network 4 (Classical)

4. SVM

◦ KNN ✓

◦ SVM

5. Clustering - K-Mean

6. Dimension Reduction PCA

7. Advanced

Decision Tree


- Explainable

- A.I.

* Supervised Learning type

- Classification $y \in \{c_1, \dots, c_k\}$; y : Data Set

Input $\rightarrow$ Decision Tree $\rightarrow$ gen model $\rightarrow$ result



If-else $\rightarrow$ rule representation

Obj making model Decision Tree

model

ID3 Iterative Dichotomiser 3 ; วนซ้ำ

• Entropy ไม้เป็น Entropy .0 ✓

- A measure of the impurity in collection of examples
→ วัดความไม่บริสุทธิ์ของ data

binary class (คือ 2)

$$H(S) = -P_0 \log_2 P_0 - P_1 \log_2 P_1$$

Multi class (> 2)

$$H(S) = -\sum_{i=1}^K P_i \log_2 P_i, \quad K = \text{จำนวน Class}$$

Information Gain $\rightarrow$ IG $\uparrow$ ยิ่งมาก ยิ่งดี ยิ่งแม่นยำ

• เลือก Feature ที่สามารถลดความไม่บริสุทธิ์ของ data ได้มากที่สุด Entropy ลด

ขั้นตอนที่ 1

1. คำนวณ Entropy ของ S : คำนวณ Entropy ของ data ทั้งหมด S ที่เราต้องการใช้

$$\text{Entropy}(S) = -\sum_{i=1}^K P_i \log_2 P_i ; P_i = \text{ความน่าจะเป็นของ class } i$$

2. เลือก Feature ที่ทำให้ IG สูงที่สุด Information Gain : คำนวณ Information Gain ของ Feature ของเรา

$$\text{IG}(S, A) = \text{Entropy}(S) - \sum_{i=1}^K \left| \frac{S_i}{S} \right| \times \text{Entropy}(S_i)$$

• เลือก Feature ที่ IG สูงที่สุด

3. สร้าง Decision Tree

S3 Random Forest

• Reduce overfit

๑๕ Majority votes

สุ่ม 10 ต้น สุ่ม 10 → ๑๕ majority votes

↓
เลือก, เอา ผลลัพธ์

* Boosting

↳ ปรับปรุง model ๑๕ ครั้ง

KNN

Classification / Supervised Learning : Lazy Learning

ประมวลผลช้าๆ แต่ใช้ไม่ซับซ้อนโปรแกรมก็ง่าย

* ไม่มี model

Algorithm

Step 1

Find distance testing data vs training data by Euclidean Distance

$$d(p, q) = \sqrt{\sum_{i=1}^N (p_i - q_i)^2}$$

Step 2

Sort distance from min to max value

การคำนวณวิธีวัดความใกล้เคียง ความเหมือน (Similarity) วัดจาก Distance ยิ่งใกล้ยิ่ง

Step 3

pick "K" items

Step 4

Majority vote

Fix issue maybe

1. Fix Slow testing time for big data
แก้ปัญหานี้

issues 1

$$x_i \gg x_j$$

e.g. $x_i = \text{house price}$ $\frac{120,000,000}{60}$
 $x_j = \text{age}$



Solution: Feature scaling $\begin{cases} \text{Z-score} & (-3, 3) \\ \text{minmax} & [0, 1] \end{cases}$

Issue 2

Noise data

ଆବଶ୍ୟକ (Criteria feature selection)
ଆବଶ୍ୟକ Gridsearch ପଦ୍ଧତି

→ Feature selection

→ Random Forest: ଆବଶ୍ୟକ feature ଚିନିଟି } base on
threshold ନିର୍ଦ୍ଧାରଣ

→ Lasso ଆବଶ୍ୟକ feature ନିର୍ଦ୍ଧାରଣ

→ RFE (Recursive Feature Elimination)


→ PCA (Principal Component Analysis)

Issue 3

Slow testing time for big data

→ KD-Trees

organize data.



କିଛି distance.
ତାହା ଚିହ୍ନଟ କରନ୍ତୁ

Issue 4

Storage requirement

→ Compression (zip)

Data compression tools
ex: parquet

issue 5 Curse of Dimensionality

"As the number of features grows, the amount of data (rows) we need to generalize accurately grows exponentially."

